

# Python

После установки конды, создания и входа в окружение можно пользоваться питоном либо в Jupyter Notebook либо в PyCharm, либо из командной строки.

## List

Статья про то как устроен список в питоне: <http://www.laurentluce.com/posts/python-list-implementation/>

```
In [ ]: # Можно хранить объекты любых типов
        [1, 2, 3, 'hello', False, 'we', ['qw', 1]]
```

```
In [ ]: arr = [0, 1, 2, 3, 4]
```

### Основные операции со списком:

```
In [ ]: arr.append(5) # Добавление элемента в конец списка
        arr
```

```
In [ ]: arr.extend([6, 7, 8]) # Расширение списка другим списком
        arr
```

```
In [ ]: # Выделение (срез) подсписка.
        # Обратите внимание на отрицательный индекс – отсчет с конца списка
        arr[3:-2:2]
```

### Присваивание

Присваивание - копируется ссылка на список но сам список не копируется

```
In [ ]: arr1 = arr
        arr1[0] = -1
        arr
```

### Копирование

После выполнения среза возвращается новый список с нужными элементами - происходит копирование. То есть скопировать список можно так:

```
In [ ]: arr_copy = arr[:]
        arr_copy[1] = -1
        arr
```

arr.copy() приведет к тому же самому результату

```
In [ ]: arr_copy = arr.copy()
```

Но копируются только элементы списка, и если мы сделаем элементом списка другой список, то он не будет копироваться полностью, а скопируется только указатель на него

```
In [ ]: arr.append([1,2,3])
        arr
```


```
In [ ]: arr_copy = arr[:]
        arr_copy[-1][0] = -1
        arr
```

## Глубокое копирование

Чтобы избежать этой проблемы можно использовать библиотеку copy

```
In [ ]: import copy
        arr_deepcopy = copy.deepcopy(arr)
        arr_deepcopy[-1][1] = -1
        arr
```

## О том как устроен список



```
In [ ]: import sys
```

```
In [ ]: sys.getsizeof([])
```

```
In [ ]: sys.getsizeof([1])
```

```
In [ ]: def print_list_size(l):
        list_str = f"sizeof({l})"
        print(f"{list_str:<23} == {sys.getsizeof(l)} bytes")

        l = []
        l.append(1)
        print_list_size(l) # 88 - 56 == 32 == 8 * 4 - после append выделяется память
        l.append(2)
        print_list_size(l) # Новая память не выделяется так как пока что хватает в
        l.append(3)
        print_list_size(l)
        l.append(4)
        print_list_size(l)
        l.append(5)
        print_list_size(l)
```

Больше операций со списками тут:

<https://docs.python.org/3/tutorial/datastructures.html>

## Dict - ассоциативный массив. Данные в виде пар (ключ, значение)

```
In [ ]: d = dict() # как unordered_map в C++
        d = {'ab': 1, 'srt': 2, 'qwe': 3, 'qdf': 4}
        d
```

```
In [ ]: d[[1,2,3]] = 'abc'
```

```
In [ ]: d[(1, 2, 3)] = 'abc'
        d
```

Важно помнить что порядок ключей в словаре может отличаться от того, в котором их туда добавляли! Начиная с python3.7 порядок сохраняется, но код не должен рассчитывать на то что элементы словаря или множества будут выдаваться в определенном порядке. Если нужен порядок есть collections.OrderedDict

```
In [ ]: d['ab'] = 'e'
        d
```

```
In [ ]: from collections import OrderedDict
        x = OrderedDict([(1, 2), (3, 4)])
        x[5] = 6
        print(x.items())
```

```
In [ ]: for key, value in d.items():
        print(f'key: {key}, value: {value}')
```

```
In [ ]: d.keys()
```

```
In [ ]: d.values()
```

```
In [ ]: for key, value in zip(d.keys(), d.values()):  
        print(f'key: {key}, value: {value}')
```

## Dict comprehensions

```
In [ ]: {i: i * 2 for i in range(10)}  
[i ** 2 for i in range(10)]
```

Метод `get()` - Если ключ есть в словаре то возвращается значение соответствующее этому ключу, иначе второй аргумент

```
In [ ]: d.get('ab', 2)
```

```
In [ ]: d.get('abd', 2)
```

`defaultdict` - Такой же словарь, только при обращении по новому ключу

МОЖНО ИСПОЛЬЗОВАТЬ ТО, ЧТО ЗНАЧЕНИЕМ ЯВЛЯЕТСЯ ЗАДАННЫЙ ОБЪЕКТ

```
In [ ]: from collections import defaultdict  
def_dict = defaultdict(list)  
def_dict
```

```
In [ ]: list()
```

```
In [ ]: def_dict['a'].append(1)  
def_dict
```

## Set

```
In [ ]: s = set() # Как unordered set в c++  
s = {1, 2, 2, 3, 3, 3, 4, 4, 4, 4, 5, 5}  
s
```

```
In [ ]: 4 in s
```

```
In [ ]: s.add(8)  
s
```

```
In [ ]: a = {x for x in 'abracadabra' if x not in 'abc'}  
a
```

```
In [ ]:
```

## Строки

```
In [ ]: 'asdf1jkasdf'
```

## Метод join строит строку соединяя элементы списка через разделитель

```
In [ ]: s = ' '.join([f'word{i+1}' for i in range(10)])
s
```

```
In [ ]: s[1:10] # строка это список строк из одного символа
```

## Метод split(sep) делить строку по указанному разделителю

```
In [ ]: print(s.split(' '))
```

## Загрузка текстов

```
In [191... !ls filimdb_evaluation/FILIMDB/
```

dev-b.labels	dev.texts	train.labels
dev-b.texts	test-b.texts	train.texts
dev.labels	test.texts	train_unlabeled.texts

```
In [192... from collections import defaultdict
with open(f'filimdb_evaluation/FILIMDB/train_unlabeled.texts', 'r', encoding='utf-8') as f:
    text = f.read()

words = [
    word
    for sentence in text.split('\n')
    for word in sentence.split(' ')
]
```

```
In [193... len(words)
```

```
Out[193... 11722415
```

```
In [194... words[:10]
```

```
Out[194... ['As',
'was',
'said',
'above,',
'this',
'is',
'basically',
'90210',
'on',
'Acid.']
```

## Удаление стоп слов

```
In [ ]: import random
# Пусть для примера стоп слова это 100 случайных слов из корпуса
stopwords = set(random.sample(words, 100))
len(stopwords)
```

## Поиск элемента в list vs. set

```
In [ ]: array = list(range(10 ** 7))
```

```
In [ ]: %%timeit
150000 in array
```

```
In [ ]: _set = set(range(10 ** 7))
```

```
In [ ]: %%timeit
150000 in _set
```

## Loops vs. list comprehensions

Используйте генерацию списков вместо циклов - она быстрее и занимает меньше строк кода

```
In [ ]: %%timeit
filtered_words = []
for word in words:
    if word not in stopwords:
        filtered_words.append(word)
```

```
In [ ]: %%timeit
filtered_words = [
    word
    for word in words
    if word not in stopwords
]
```

## Пример создания словаря с частотами

```
In [ ]: %%timeit
vocab = defaultdict(int)
for w in words:
    vocab[w] += 1
```

```
In [ ]: %%timeit
vocab = dict()
for w in words:
    try:
        vocab[w] += 1
    except:
        vocab[w] = 1
```

```
In [ ]: %%timeit
vocab = dict()
for w in words:
    vocab[w] = vocab.get(w, 0) + 1
```

```
In [ ]: %%timeit
vocab = dict()
for w in words:
    if w in vocab:
        vocab[w] += 1
    else:
        vocab[w] = 1
```

```
In [ ]:
```

```
In [ ]:
```

## Полезные ссылки

Несколько различных кратких введений в python:

1. <https://docs.python.org/3/tutorial/>
2. <https://www.learnpython.org/>
3. [https://en.wikibooks.org/wiki/A\\_Beginner's\\_Python\\_Tutorial](https://en.wikibooks.org/wiki/A_Beginner's_Python_Tutorial)
4. Статья об особенностях jupyter notebook:  
<https://habr.com/ru/company/wunderfund/blog/316826/>

Существуют также интерактивные курсы. К примеру, <https://www.codecademy.com> - курс learn python